



RST-Train Codebase

Qwen3.5 终端任务训练、评测与自我改进流水线

SFT

DPO DEFAULT

GRPO OPT-IN

RSI LOOP

2026-09-03

这个仓库解决什么

OBJECTIVE

Agentic Training

把 RST 终端任务轨迹变成
Qwen3.5 的可复现 SFT /
DPO / RL 路径

PRIMARY BACKEND

verl + FSDP

主路径服务 4x8 A100 ;
slime/Megatron 保留为次级
路径

CORE CONTRACT

loss mask

Qwen3.5 的监督边界先离线固
化，再交给 trainer

CURRENT STATE

Ops Repo

重点不是库 API，而是能被审
计的集群运行和报告

```
$ MODEL_KEY=qwen3.5-9b bash scripts/20_run_all.sh  
SFT -> eval -> report -> DPO  
RUN_RL=1 才进入 agentic GRPO
```

POSITIONING

它不是严格 MAS

当前系统

一个 policy agent 解终端任务；程序 verifier 给 reward；LLM judge 只在离线数据策展边界带发表意见。它更准确地叫 agentic self-improvement pipeline。

MAS 扩展方向

把 solver、critic、planner、repair agent 变成有通信协议和共享状态的多个自治角色，再由 verifier 保持最终 reward 的可比性。



主链路是编号脚本

00-02

Preflight

环境、sandbox、模型和数据下载

03 / 15

Data

轨迹重建、mask 校验、预 tokenization

30

SFT

verl + FSDP2, 带显存和 kernel 门禁

07 / 08

Export

合并 shard, 恢复 vision / MTP

06 / 06B

Eval

agentic eval 或离线 fallback

14

Report

FAIL / WARN / OK 与 verdict.json

33

DPO

默认后训练, 无容器依赖

12 / 21

RL / RSI

GRPO opt-in; RSI 生成新 SFT 数据

训练安全性来自一条硬契约

FIXED

统一 chat template

Qwen3.5 家族共用同一 tokenizer 和训练模板，不按模型重新切数据。

MASK

`qwen3_5` loss mask

只训练 assistant 目标段，不能训练 user、system、harness 输出。

PRETOK

`input_ids +`
`loss_mask`

verl 直接消费离线产物，避免 MultiTurnSFTDataset 每轮注入 think block。

GATE

首 token 不可监督

防止 packed batch 的 cyclic roll 把监督泄漏到样本边界。

AUDIT

两份 mask 实现互验

构建器与 validator 分开实现，同一 conversation 必须给出一致 mask。

prompt / user

think opener

supervised assistant span

next turn

loss_mask = 1 only here

当前权重范围已经对齐项目模型族

SUPPORTED FAMILY

Qwen3.5

0.8B / 4B / 9B / 27B / 35B-
A3B 注册在 models.json

LOCAL CKPT DIRS

11

已覆盖 khazic 下符合项目命名的 rst-qwen3.5 权重

LARGE ARTIFACTS

~452G

data/ckpts 下当前量级，
27B-sft 同时含 FSDP 和 HF
形态

EXCLUDED

non-RST

gemma / heat / tfm /
appov3 等不在本项目 registry
内

4B

sft / ota / tmax /
nemo

主要是 FSDP shard 目录，约 17G 每组。

9B

sft / ota / tmax /
nemo

nemo 有 eval-ready HF，其他为训练 shard 形态。

27B

sft / ota / cap10

ota 和 cap10 已是 out-hf-full；sft 保留 global_step_82 与 hf。

为什么主路径是 verl + FSDP

verl + FSDP

当前主线。能在集群限制下推进 SFT，启动器前置检查 fused CE、FSDP2 梯度累积补丁、静态显存、rendezvous 和预 tokenized parquet。

slime + Megatron

保留为次级路径。优势是原生 rollout 适配，但 A100 集群上的 cuDNN 和 ops 条件更难满足，当前不是默认。



设计原则

训练脚本不是“尽量启动”，而是先证明配置可运行。能在 30 秒内发现的错误，不应该等 32 个进程加载完权重后才暴露。

text-only 训练后必须恢复完整模型

FSDP SHARD

global_step_N

要求 rank 文件完整，拒绝混合 world size

MERGE

HF weights

优先 verl merger，失败走本仓库兼容实现

RESTORE

vision / MTP

从原始 checkpoint 流式补回未训练模块

DIFF

trust gate

确认 text stack 变了，视觉侧边文件齐全

07

restore_vision

复制 `model.visual.*` 和 `mtp.*`，默认拒绝未知 fallback。

08

prepare_eval_ckpt

能识别已合并 HF 目录，也能从 Hub 只拉取所需 shard。

RISK

ranko log

BUG.md 记录 ranko 训练日志仍需保留，方便静态显存核验。

verifier 是 reward , LLM judge 不是 reward

Agentic eval

`06_eval.py` 用 SGLang + Harbor + Terminus-2 运行任务。
基础设施故障不进分母；agent 预算失败留在分母且 reward 为 0。

Offline fallback

`06b_eval_offline.py` 做 teacher-forced scoring 和 action protocol probe。它不是 pass rate，但能在 sandbox 不可用时给 checkpoint 质量信号。

OK: checkpoint + measurement

WARN

FAIL

verdict.json: in_range gates GRPO, checkpoint_trustworthy gates DPO

默认 DPO , 可选 GRPO , 新增 RSI

DPO

default

无需容器；0.8B/H100 已端到端跑通，
multi-rank 仍待实测。

GRPO

opt-in

需要 sandbox；`RUN_RL=1` 才进入
agentic rollout。

RSI

new loop

把本模型成功 rollout 重新变成 SFT
parquet。

SAMPLE

06_eval

必须带 `export-
trajectories`，保留
`raw_content`

→

HARVEST

03h

`reward >= 1` 的 rollout 进入
`messages parquet`

→

CURATE

03g

启发式全量，LLM 只看
`borderline`


→

TRAIN

15 + 30

混入 `seed corpus`，再预
tokenized SFT

judge 只处理模糊数据，不参与 打分



81.0%

clear_keep

确定性启发式直接保留。

18.0%

borderline

只有这部分会调用 LLM judge，且按内容哈希缓存。

1.1%

clear_drop

重复、报错、提前完成等坏示范直接剔除。

NEVER

reward / eval / mask

LLM 意见不进入 reward，保持 benchmark 可比。

重构目标：一个定义对应一个可比较数字

NEW	<code>scripts/siblings.py</code>	统一加载数字开头脚本，避免五份 <code>spec_from_file_location</code> 漂移。
NEW	<code>scripts/sft_common.py</code>	统一 dedup、长度门、group split、token_stats。
NEW	<code>scripts/taskpool_common.py</code>	统一 RL task tier、Docker FROM、verifier leak 规则。
NEW	<code>scripts/hf_publish.py</code>	统一 Hugging Face 上传和数据卡 claim 校验。
NEW	<code>rst_common/judge.py</code>	统一 OpenAI-compatible judge、缓存、预算和 JSON contract。

WORKLOG

+515 / -837

PUBLISHED DATA

stable

本地能证明的是 CPU 约束

LOCAL RUNNER

0 fail

```
python  
tests/run_tests.py
```

OBSERVED

311 ok

当前轻量环境统计，部分模块按依赖跳过。

SKIPPED

29

torch / transformers /
numpy 缺失时跳过，不代表
GPU 路径已验证。

DESIGN

**source
gates**

大量测试钉住脚本内容和启动
门禁，而非只跑 mock。



```
$ python tests/run_tests.py
```

```
OK: 0 failure(s)
```

GPU、transformers、numpy 相关路径需要对应环境复测

OPEN RISKS

需要集群或真实 rollout 才能关闭

OPEN-1

4-node FSDP2
throughput

TCP 拓扑可能吞吐受限，需要测量后决定是否用 HSDP。

OPEN-2

Ulysses SP correctness Gated-delta-net + SP 路径需要与 sp=1 对齐 loss 曲线。

OPEN-3

vision / MTP 未训练 已恢复但未训练；是否冻结和显存收益仍需实测。

OPEN-4

ranko log 需要保留 ranko stdout，才能审计 FSDP 静态 footprint。

OPEN-5

cluster code freshness 集群实际拉取版本要明确，不能只看本地 cached ref。

下一步应该验证什么

1

Raw rollout

跑一次带 `--export-trajectories` 的真实 Harbor eval, 关闭 BUG-19 raw path 风险



2

SP check

同 seed、同数据, sp=1 vs sp=8 小步 loss 曲线对照



3

27B SFT

确认 fused CE、FSDP2 patch、token budget gate 均在日志出现



4

DPO multi-rank

验证修复后的 sharding layout 在 torchrun 下可过 step-0 gate



```
$ MODEL_KEY=qwen3.5-27b bash scripts/20_run_all.sh
$ MODEL_KEY=qwen3.5-27b RUN_RL=1 bash scripts/20_run_all.sh
先测量, 再把 README 状态从 UNVERIFIED 提升为 run
```



Bottom Line

当前 repo 已经具备可审计的训练闭环；下一步的价值在集群实测，而不是继续堆脚本。

mask correctness

checkpoint integrity

verifier reward

RSI data loop